Синтаксические структуры

Лекция 1

Основные определения

Язык - всякое средство, включающее:

- знаковую систему, т.е. множество допустимых последовательностей знаков;
- множество смыслов этих последовательностей знаков;
- соответствие между последовательностями знаков и смыслами, делающее «осмысленными» допустимые последовательности знаков.

Математическая лингвистика – наука, занимающаяся формальными методами построения и изучения языков.

Основные разделы общей лингвистики

- синтактика
- семантика
- Прагматика
- *Синтактика* – изучает правила развертывания языка в пространстве или во времени, направлена на изучение формы (структуры), словосочетаний, предложений, текста. Изучение структуры слов выделяется в лексический анализ языка.
- Синтаксический анализ основан на части грамматики, имеющей дело с единицами, более протяженными, чем слово, – словосочетаниями и предложениями.
- В результате синтаксического анализа линейная последовательность слов преобразуется в набор синтаксических отношений.

- «Сырые дрова плохо горят»
- [Сырые], [дрова], [плохо] и [горят]
- [Сырые дрова] [плохо горят]
- «сырые» – определение при слове «дрова», а «горят» – сказуемое.

Грамматика

- Предложения, построенные в соответствии с грамматикой языка, являются связными, то есть лишенными разрывов в цепочке синтаксических отношений.
- отношения являются бинарными
- синтаксические зависимости не всегда связывают слова, находящиеся рядом в цепочке слов
- альтернативные варианты разбора, связанные с многозначностью входных данных.

Семантика. Треугольник Фреге и модель коммуникации

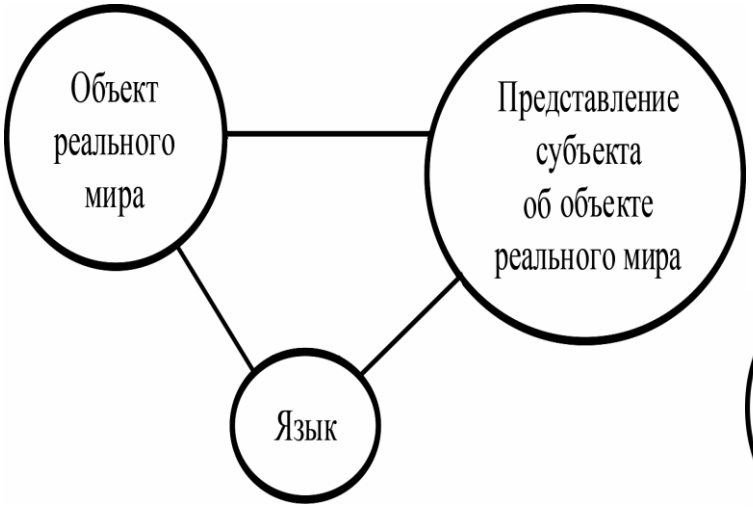

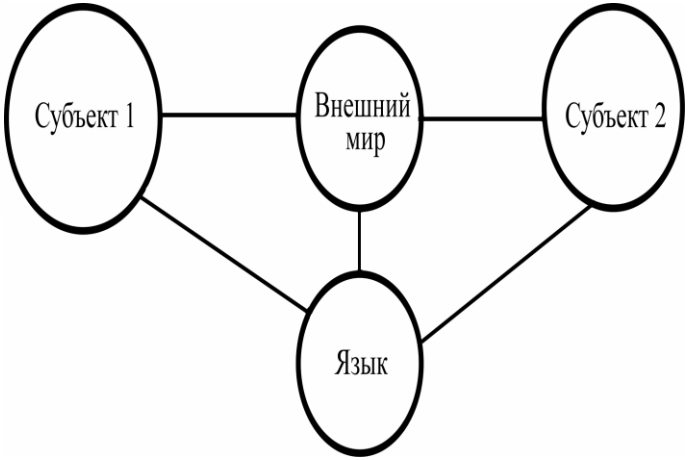

Семантический анализ

- Выделение сем (компонент значения)

«холостяк» = [взрослый] [неженатый] [мужчина]

«мужчина» = [человек] [мужского пола]

- Семантический граф (семантическая сеть)
- Модель фреймов

Синтаксические структуры

- Системы составляющих
- Деревья зависимостей (деревья подчинения)
- Ямщик сидит на облучке (Пушкин А.С.)
- [Ямщик][сидит[на облучке]]

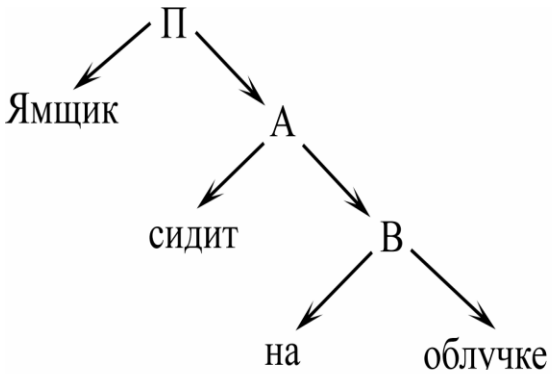

а

б

Системы составляющих

- Пусть α – произвольная непустая последовательность символов в алфавите *A*. Вхождения символов в последовательность будем называть ее **точками**.
- Определим понятие **отрезка последовательности** как множество точек последовательности α таких, что

$\{x: a \le x \le b\}$, где a, b – фиксированные точки,

$a \le x$ означает «точка a расположена раньше по тексту или совпадает с x; $x \le b$ понимаем аналогично.

Системы составляющих

- Множество *C* отрезков последовательности α называется **системой составляющих** этой последовательности, если:

а) *C* содержит отрезок, состоящий из всех точек α, и все одноточечные отрезки α (тривиальные составляющие);

б) любые два отрезка из *C* либо не пересекаются, либо один из них содержится в другом (нетривиальные составляющие).

Системы составляющих

- Если алфавит *A* интерпретируется как множество слов языка и α – как предложение,
  то при подходящем выборе системы составляющих для α
  нетривиальные составляющие представляют собой **словосочетания**, т.е. группы слов (синтаксически связанные части предложения).

Примеры

- «Каждый из нас должен научиться понимать труд как творчество»;
- «if $a > b$ then $a := b$ else $a := b - a$»;
- «$\forall x\ P(x)\ \&\ Q(x) \Leftrightarrow \neg P(x) \vee \neg Q(x)$»

Составляющие:

[Каждый из нас] [должен научиться понимать] [труд] [как творчество];

- if [$a > b$] then [$a := b$] else [$a := b - a$];
- [$\forall x$] [[[$P(x)$] & [$Q(x)$]] $\Leftrightarrow$ [[$\neg$ [$P(x)$]] $\vee$[$\neg$ [$Q(x)$]]]].

Альтернативы (системы соглашений)

- [Все [эти известия]] [произвели [на меня] [удручающее впечатление]]
- [Все [эти известия]] [произвели] [на меня] [удручающее впечатление]

Синтаксическая омонимия

- Геологи и студенты из Тюмени уехали в Москву
- [[Геологи и студенты] [из Тюмени] [уехали [в Москву]] –
- «тюменские геологи и тюменские студенты уехали откуда-то, необязательно из Тюмени, в Москву»;
- [Геологи и [студенты [из Тюмени]] [уехали [в Москву] –
- «какие-то, необязательно тюменские, геологи и тюменские студенты уехали откуда-то, не обязательно из Тюмени, в Москву»;
- [Геологи и студенты] [[из Тюмени] уехали [в Москву]] –
- «какие-то, не обязательно тюменские, геологи и какие-то, не обязательно тюменские, студенты уехали из Тюмени в Москву».

Грамматики ЕЯ

- **Грамматика зависимостей** – теория синтаксической структуры предложения. Согласно грамматике зависимостей, связи между членами предложении рассматриваются как подчинительные, а сказуемое признаётся вершиной предложения. В результате синтаксического анализа на основе грамматики зависимостей строится **дерево синтаксических зависимостей**
- **Грамматика составляющих** – теория синтаксической структуры предложения. Согласно грамматике составляющих, сложные грамматические единицы предложения складываются из более простых непересекающихся грамматических единиц.

Грамматика составляющих

- В грамматике составляющих строится иерархия составляющих, где слова в предложении группируются на основе их части речи в именные, глагольные, прилагательные, предложные и наречные группы.
- Каждая группа состоит из более простых, не пересекающихся единиц, а вершиной группы считается слово соответствующей части речи (например, в именной группе вершина существительное).

Дерево составляющих предложения «This is an example of constituency grammar»

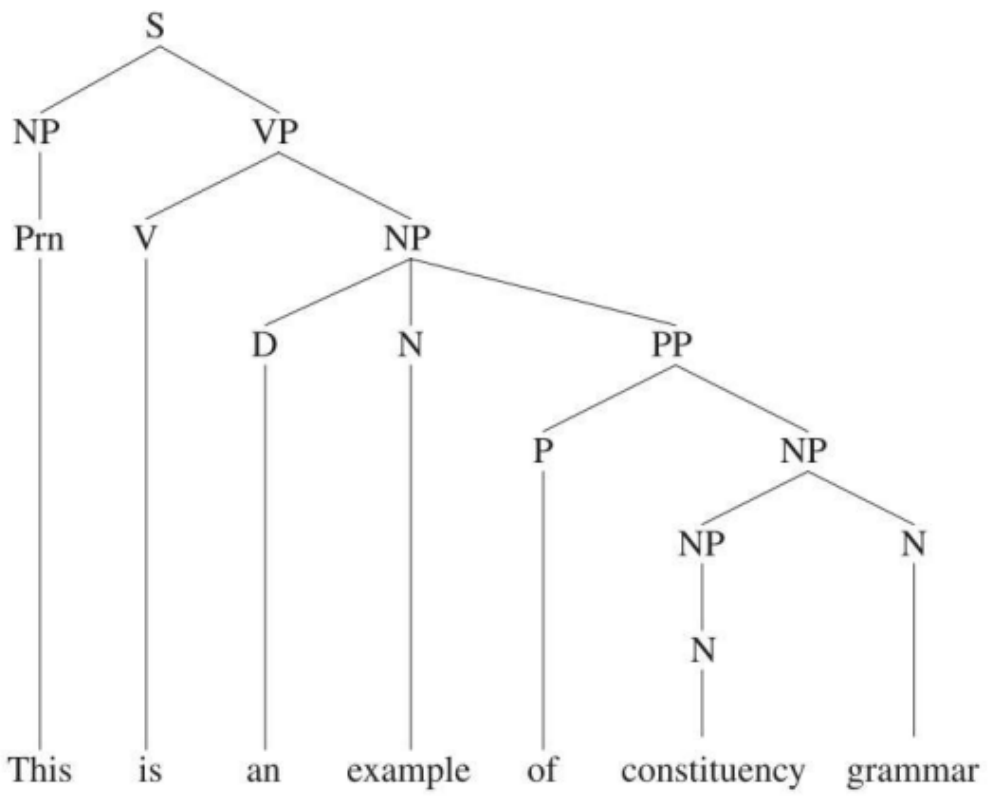

Грамматика зависимостей

- В грамматике зависимостей все отношения между членами предложения считаются подчинительными.
- Структура предложения представляется в виде **дерева зависимостей**, иерархии членов предложения, где на вершине сказуемое, а остальные слова – его подчиненные .

Дерево зависимостей предложения «Bills on ports and immigration were submitted by Senator Brownback, Republican of Kansas»

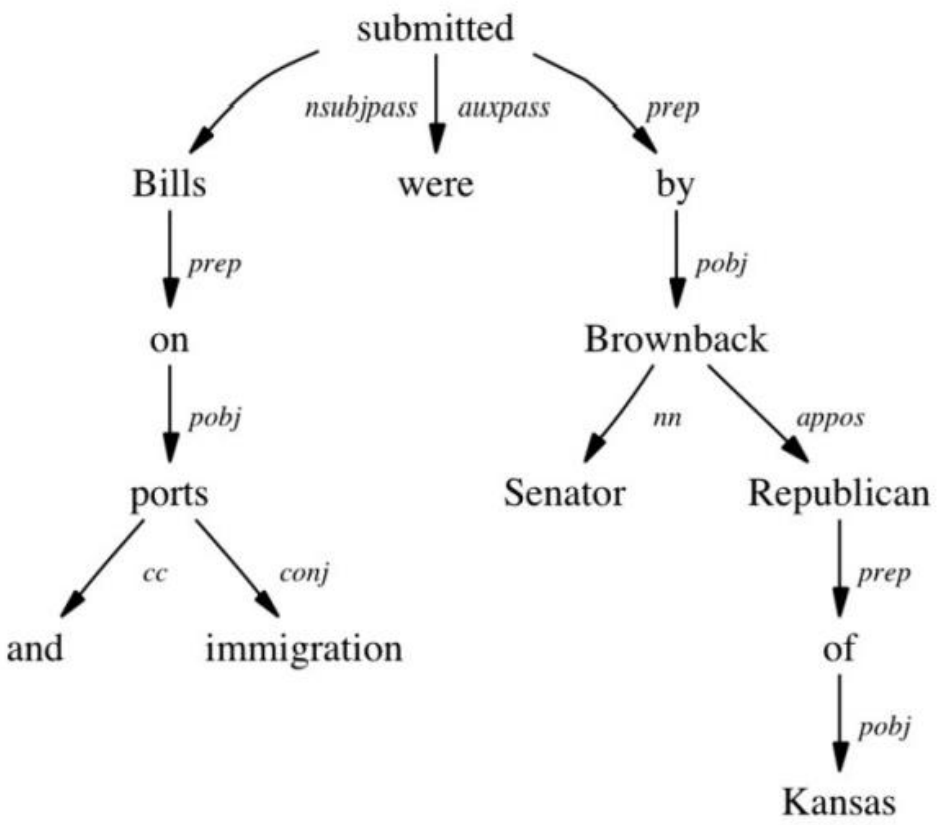

Дерево зависимостей предложения «Economic news had little effect on financial markets.»

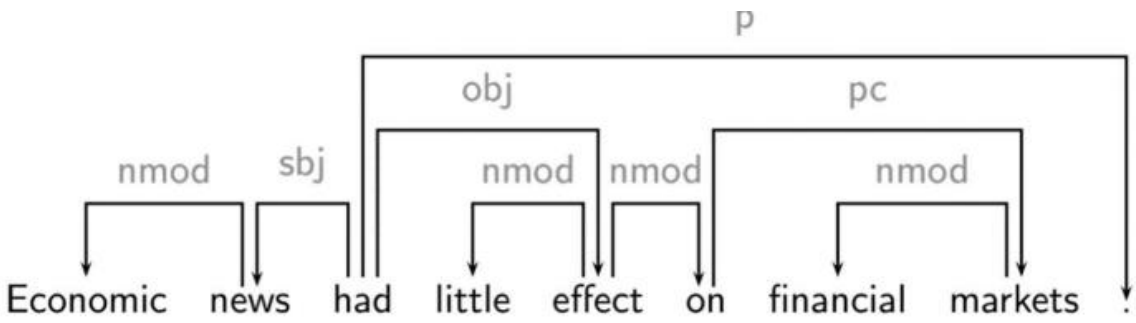

Дерево разбора предложения «This is an example of dependency grammar»

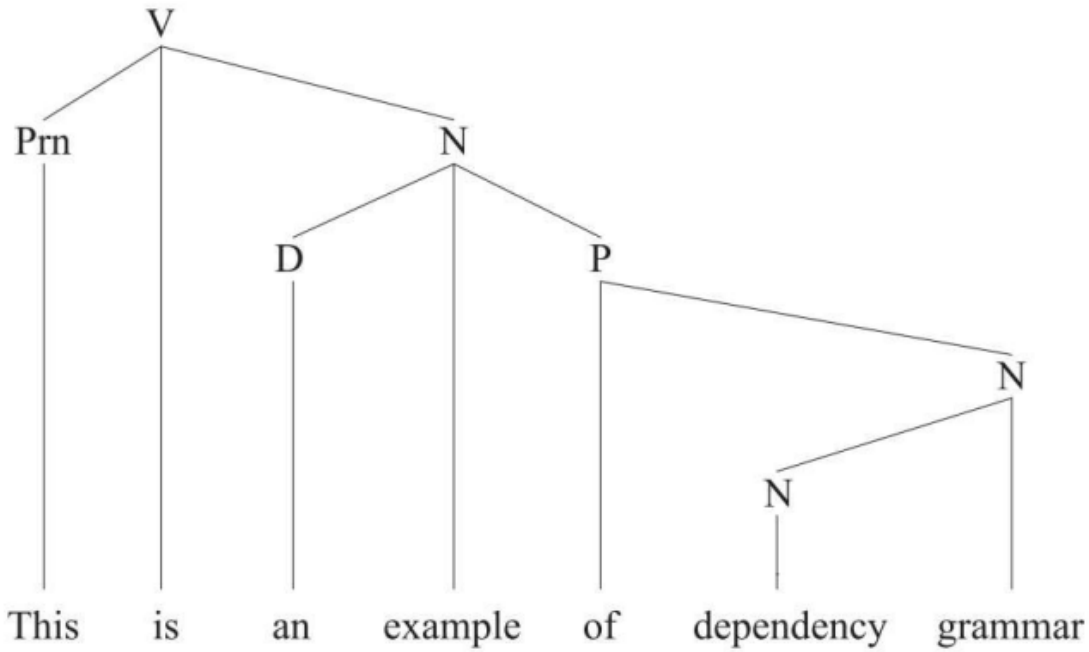

Деревья составляющих

- Определение. Если *A* и *B* – составляющие некоторой системы *C*, то выражение «*B* непосредственно вложено в *A*» будет означать, что $A \supset B$ и в *C* нет составляющей, вложенной в *A*, содержащей *B* и отличной от *A* и от *B*.
- Если на системе составляющих *C* введено отношение непосредственного вложения, то *C* представляет собой по этому отношению дерево.
- Корнем дерева является составляющая, состоящая из всех точек последовательности, листьями – одноточечные отрезки, а промежуточными вершинами – все нетривиальные составляющие. Такое дерево получило название **дерева составляющих**.

[Объединение [двух [замкнутых множеств]]]
[есть [замкнутое множество]]

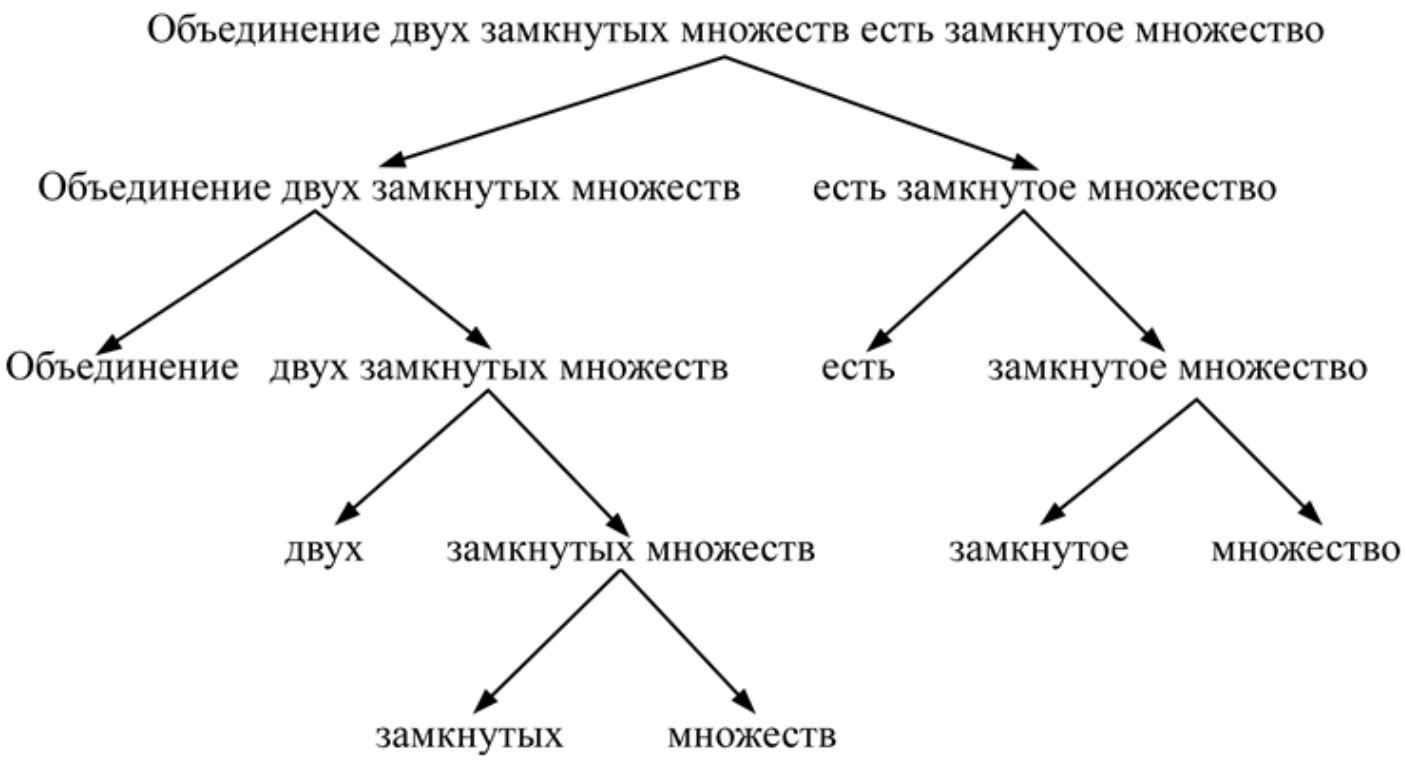

Размеченное дерево составляющих

- При описании предложения с помощью системы составляющих часто используются метки, которые представляют собой синтаксические характеристики словосочетаний и интерпретируются как символы синтаксических классов слов и словосочетаний.
- Упорядоченная тройка < *C*, *M*, *F* >, где *C* – система составляющих; *M* – множество меток; *F* – отображение *C* в *M*, называется размеченной системой составляющих, а дерево составляющих – **размеченным деревом составляющих**.

Размеченное дерево составляющих

- <u>Пример 1.</u> Пусть множество *M* содержит следующие элементы:
- ПРЕДЛ – предложение;
- $ГГ_{рчвл}$ – группа непереходного глагола в роде р, числе ч, времени в и лице л;
- $Г_{рчвл}$ – переходный глагол в роде р, числе ч, времени в и лице л;
- $ГС_{рчп}$ – группа существительных рода р, числа ч и падежа п;
- $С_{рчп}$ – существительное рода р, числа ч и падежа п;
- $П_{рчп}$ – прилагательное рода р, числа ч и падежа п;
- НГ – предложная группа с предлогом «на»;
- Н – предлог «на».

[Онегин, [добрый [мой приятель]]], [родился [на [брегах Невы]]]

[Онегин, [добрый [мой приятель]]], [родился [на [брегах Невы]]]

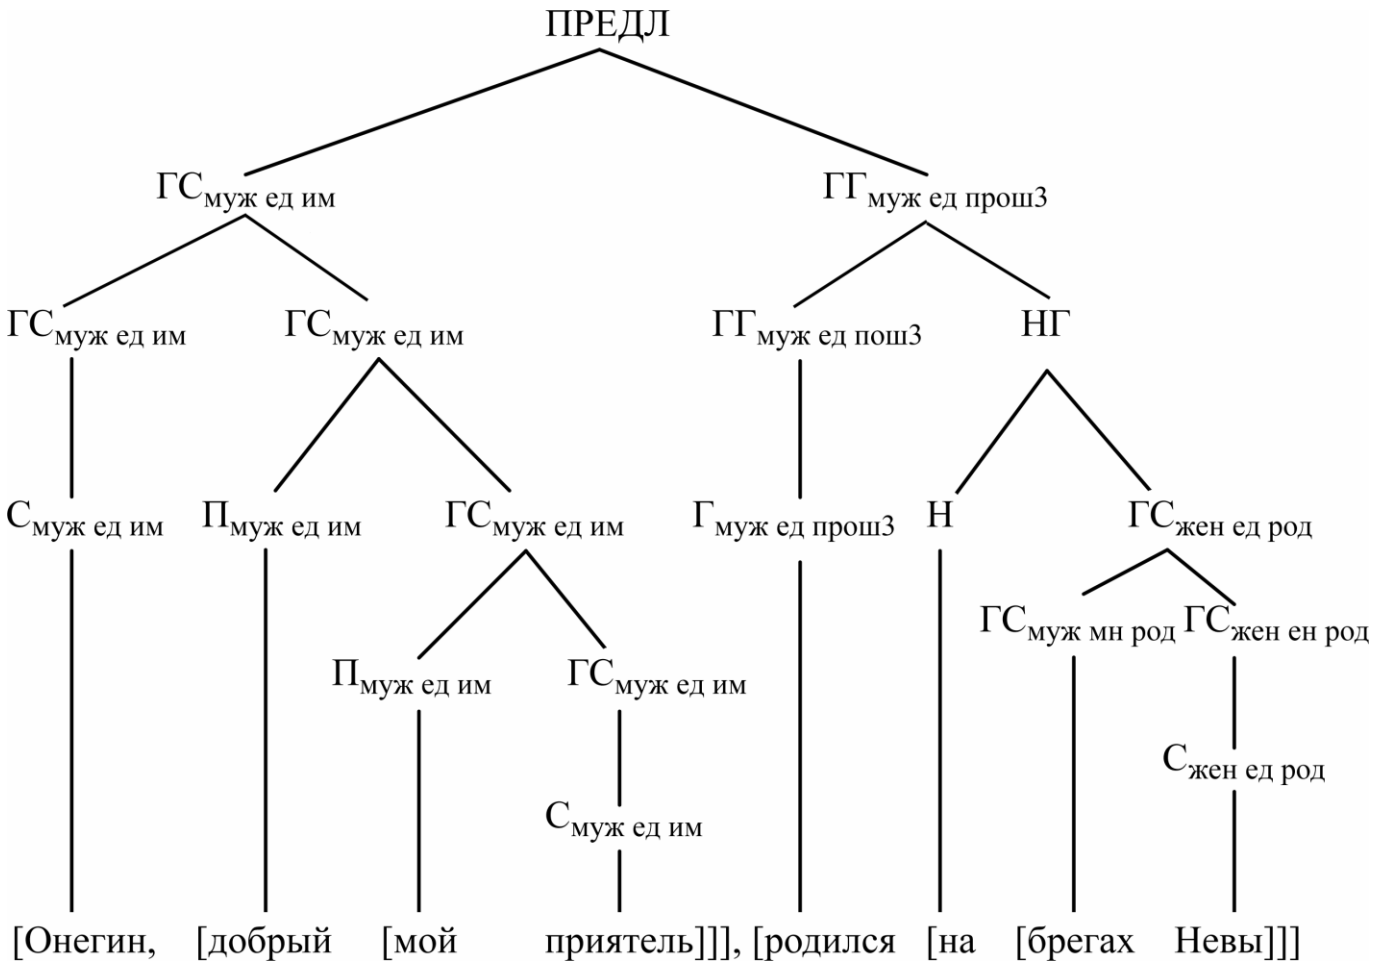

<u>Пример 2.</u> Система составляющих

[if] [[*a*] [>] [*b*]] [then] [[*a*] [:=] [*b*]] [else] [[*a*] [:=] [[*b*] [–] [*a*]]]

ОПЕР_УСЛ

Метки (пример 2)

- ОПЕР – оператор;
- ОПЕР_УСЛ – условный оператор;
- ОПЕР_ПРИСВ – оператор присваивания;
- АРИФ_ВЫР – арифметическое выражение;
- ЛОГ_ВЫР – логическое выражение (отношение);
- ИДЕН – идентификатор;
- БОЛ – операция больше;
- ЗАР_ПРИСВ – зарезервированное слово; = (присваивание);
- ЗАР_МИНУС – зарезервированное слово; – (минус);
- ЗАР_IF – зарезервированное слово if;
- ЗАР_THEN – зарезервированное слово then;
- ЗАР_ELSE – зарезервированное слово else.

Сравнение грамматик

- Синтаксический анализ на основе деревьев зависимостей в последние годы становится все более популярным по сравнению с анализом составляющих.
- Одной из возможных причин растущего интереса является то, что грамматика зависимостей лучше, чем грамматика составляющих, подходит для анализа языков, которые демонстрируют свободный или гибкий порядок слов и где лексические и морфологические признаки играют более важную роль при определении синтаксической структуры предложения, чем порядок слов

Сравнение парсеров

- По сравнению с грамматикой составляющих, парсеры зависимостей имеют следующие преимущества:

1) Связи зависимостей между словами близки к их семантическим отношениям,.
2) В дереве зависимостей каждому слову из предложения соответствует только одна вершина.
3) Парсер зависимостей обрабатывает члены предложения «по одному», в отличие от парсеров составляющих, где обработка члена предложения заканчивается только после нахождения всех групп, к которым он принадлежит.
4) Исследования также показывают, что человеческий разум обрабатывает предложения примерно по такому же принципу, что и парсеры зависимостей.
5) Существующие алгоритмы анализа зависимостей значительно быстрее, чем алгоритмы анализа составляющих